



Escuela
Politécnica
Superior

Análisis de sentimiento y tendencias en campañas electorales



Máster Universitario en Ciencia de Datos

Trabajo Fin de Máster

Autora:

Jimena Milla Moreno

Tutor:

Miguel Ángel Teruel Martínez

Junio 2026



Universitat d'Alacant
Universidad de Alicante

Análisis de sentimiento y tendencias en campañas electorales

Autora

Jimena Milla Moreno

Tutor

Miguel Ángel Teruel Martínez



Máster Universitario en Ciencia de Datos



Escuela
Politécnica
Superior



Universitat d'Alacant
Universidad de Alicante

ALICANTE, junio 2026

Resumen

Agradecimientos

Índice general

1	Introducción	1
1.1	El sentimiento en Machine Learning	1
1.2	Twitter como fuente de datos	2
1.3	Motivación	3
2	Estado del arte	7
2.1	Tareas de clasificación de opinión en Twitter	7
2.1.1	Sentiment Analysis (Análisis de Sentimiento)	7
2.1.2	Stance Detection (Detección de Postura)	7
2.2	Enfoques en TSA	8
2.3	Enfoque en análisis de Tópicos: LDA	9
2.4	Preprocesamiento en Twitter	10
2.5	Benchmarks y Evaluación: TweetEval	10
2.5.1	Estructura del benchmark y formato de los datos	11
2.5.2	Análisis exploratorio de los datos	15
3	Fundamentos teóricos	21
3.1	Arquitecturas de modelos de lenguaje	21
3.1.1	Transformers	21
3.1.2	BERT: <i>Bidirectional Encoder Representations from Transformers</i>	25
3.1.3	Modelado de tópicos: el LDA	30
3.2	Métricas de evaluación	30
3.2.1	Métricas Básicas de Clasificación	31
3.2.2	F1-Score Macro: Métrica Principal	32
3.2.3	F1-Average para Stance Detection	32
4	Metodología	35
5	Análisis de resultados	37
6	Conclusiones	39
	Bibliografía	41

Índice de figuras

2.1	Estructura de directorios y archivos del repositorio TweetEval.	11
2.2	Estructura interna de archivos para la tarea de Sentiment Analysis.	12
2.3	Organización jerárquica del dataset para la tarea de Stance Detection por tópicos.	13
2.4	Distribución de clases por split en el dataset de Sentiment Analysis.	15
2.5	Distribución de longitud de los tweets en el conjunto de entrenamiento en el dataset de Sentiment Analysis.	16
2.6	Tokens más frecuentes en el dataset separando por clase.	16
2.7	<i>Hashtags</i> más frecuentes en el dataset de sentimiento.	17
2.8	Distribuciones porcentuales a favor/neutral/en contra para los distintos tópicos del dataset	18
2.9	Distribuciones del split para los distintos tópicos del dataset de Stance Detection.	19
2.10	Longitud de los tweets para los distintos tópicos del dataset de Stance.	19
2.11	Top 12 tokens más frecuentes para los tweets de los distintos tópicos del dataset de Stance.	20
3.1	Arquitectura general del transformer. Adaptado de pTRANSFORMERS	22
3.2	Resultado de la enmascaración de la matriz $Q \cdot K$ para una frase de ejem- plo. Adaptado de [Pérez, 2020]	24
3.3	Entrenamiento de destilación, para el que no se usa el conjunto de entre- namiento entero sino un conjunto conocido como “transfer set”. Adaptado de [Mohan, 2022]	28
3.4	Evolución cronológica de los Modelos de Lenguaje basándose en su nú- mero de parámetros (en millones). Se observa una tendencia exponencial hacia modelos de gran escala, contrastando con versiones destiladas (Dis- tilBERT) que buscan la eficiencia, lo cual en ocasiones puede ser clave para tareas de análisis en tiempo real, donde la inmediatez es lo primor- dial. Adaptado de [Pérez, 2020]	30

Índice de tablas

2.1	Ejemplos de análisis de sentimiento en Tweets	7
2.2	Ejemplos de Postura (Stance) en Tweets sobre el Brexit	8
2.3	Distribución de muestras y observaciones por target para stance detection	14
2.4	Resultados de F1-macro por Tarea y Modelo	15
3.1	Comparativa de rendimiento F1-Macro entre modelos basados en Trans- formers para Sentiment Analysis.	21
3.2	Estructura de la matriz de confusión para clasificación binaria.	31

1 Introducción

El análisis de sentimiento a través de bases de datos obtenidas por medio de escraqueo de redes sociales es un campo de estudio relativamente reciente que ha empezado a generar interés público en los últimos años.

En particular, el análisis de sentimiento en Twitter (TSA) aborda el problema de analizar los mensajes publicados en esta plataforma en términos del sentimiento y las opiniones que expresan. A diferencia del análisis de sentimiento tradicional aplicado a reseñas de productos o artículos de noticias, el TSA presenta desafíos únicos derivados de las características particulares de Twitter que comentaremos en la siguiente sección [Giachanou and Crestani, 2016].

Este uso en concreto de las plataformas sociales por parte de los usuarios de expresar ideas, opiniones y sentimiento, ha generado una cantidad masiva de datos e información que representa una valiosa fuente de opinión pública que puede ser aprovechada en diversos contextos, especialmente en el ámbito político.

Durante las campañas electorales, millones de usuarios expresan sus posiciones, emociones y preferencias políticas en tiempo real, creando un ecosistema informativo sin precedentes. Sin embargo, este mismo ecosistema se ha convertido también en un terreno fértil para la manipulación política y la desinformación, donde actores malintencionados pueden influir en la opinión pública mediante el uso de bots, trolls y campañas coordinadas de información falsa.

Twitter (actualmente X) ha desempeñado un papel crucial en las campañas electorales modernas y será la fuente con la que más trabajaremos a lo largo de este trabajo. Desde las elecciones presidenciales de Estados Unidos en 2016, pasando por el referéndum del Brexit en Reino Unido, hasta las elecciones italianas de 2022, Twitter se ha consolidado como un espacio donde se libran batallas por la opinión pública. Estudios recientes han documentado casos de interferencia extranjera [Bovet and Makse, 2019], uso masivo de bots para amplificar mensajes políticos [Bessi and Ferrara, 2016], y campañas de desinformación sistemática [Shao et al., 2018] que han tenido impactos medibles en los resultados electorales.

1.1. El sentimiento en Machine Learning

El sentimiento se refiere a la actitud, emoción u opinión que expresa una persona hacia una entidad, tema o evento específico.

El análisis de sentimiento es la tarea del Procesamiento del Lenguaje Natural (PLN) que se encarga de la detección y clasificación de sentimientos en textos. La característica fundamental del sentimiento es su polaridad, que representa la orientación afectiva de

una opinión. Por lo general, los niveles considerados para clasificar la polaridad son:

- “positivo”: expresa aprobación, satisfacción o emociones favorables.
- “negativo”: expresa desaprobación, insatisfacción o emociones desfavorables.
- “neutro”: no expresa una orientación afectiva clara por lo que no es posible clasificar el sentimiento como positivo o negativo y/o presenta información objetiva sin aportar ningún tipo de juicio de valor.

Aunque en algunos casos se añaden categorías de granularidad fina (por ejemplo, “muy positivo” y “muy negativo”) o solo se tienen en cuenta las clases “positivo” y “negativo” [Balahur, 2013]. No obstante; para este trabajo, adoptaremos la clasificación ternaria (positivo, negativo, neutral) que es el estándar en la mayoría de estudios del campo.

Otra tarea relacionada con este tema es la detección de emociones, que se refiere a la clasificación de texto en varias clases de emociones, usualmente las básicas, según lo descrito por Paul Ekman [Ekman, 1992]. Aunque son diferentes en ciertos aspectos, parte de la investigación en este campo ha considerado estas tareas de forma conjunta bajo el concepto general (o “paraguas”) del análisis de sentimiento. Una tarea complementaria al análisis de sentimiento es la detección de postura (stance detection) [Mohammad et al., 2016], que tiene como objetivo identificar la posición del autor respecto a un target específico (una persona, tema o propuesta). A diferencia del análisis de sentimiento, que detecta la polaridad emocional general del texto (positivo, negativo, neutral), la detección de postura clasifica si el autor está a favor, en contra o no expresa una postura clara hacia una entidad concreta. Esta distinción resulta especialmente relevante en el análisis de campañas electorales, donde interesa conocer no solo el tono del debate (sentimiento) sino también el posicionamiento específico hacia candidatos o propuestas (postura). Aunque este trabajo se centra principalmente en el análisis de sentimiento, se explorará opcionalmente la detección de postura como análisis complementario en casos específicos como el Brexit, donde el debate se articuló claramente en torno a dos posiciones (Leave vs. Remain).

Algunos desafíos propios del análisis de sentimiento de textos son tratar con el sarcasmo, la negación y la ironía; saber identificar correctamente el sentimiento en función del contexto que puede estar presente de forma explícita o no en el texto, y hacer frente a las múltiples interpretaciones dadas por la ambigüedad.

Así, cuando en un texto aparece escrito por ejemplo “Trump es único”, ese “único”, ¿es un elogio o una crítica?

1.2. Twitter como fuente de datos

La elección de Twitter como fuente de datos para este trabajo responde a una serie de características únicas de la plataforma que la convierten en un recurso especialmente valioso para el análisis del discurso político y la opinión pública.

En primer lugar, desde su lanzamiento en 2006, Twitter ha atraído a cientos de millones de usuarios que publican más de 500 millones de mensajes diarios. Esta escala

masiva proporciona un volumen de datos suficiente para realizar análisis estadísticamente significativos sobre cualquier evento político.

En segundo lugar, a diferencia de plataformas como Facebook, donde la mayoría del contenido es privado, los tweets son accesibles públicamente en su mayor parte, lo que facilita la recopilación de datos para investigación.

En tercer lugar y desde el punto de vista metodológico, los tweets presentan también ventajas significativas. Su estructura estandarizada incluye metadatos ricos como marcas temporales, geolocalización, hashtags, menciones y estadísticas de interacción (retweets, likes), que permiten enriquecer el análisis más allá del contenido textual. Los hashtags, en particular, han demostrado ser indicadores fiables de la relevancia temática de un tweet y permiten rastrear conversaciones específicas sobre candidatos, partidos o eventos electorales [Giachanou and Crestani, 2016].

Un factor determinante en la elección de Twitter como fuente de datos es la existencia de benchmarks y datasets académicamente validados construidos específicamente sobre esta plataforma. En este trabajo utilizamos TweetEval [Barbieri et al., 2020] como dataset de entrenamiento del modelo de clasificación de sentimiento. TweetEval es un benchmark de referencia en el campo del PLN para Twitter, desarrollado por el grupo CardiffNLP y disponible públicamente a través de la plataforma Hugging Face. Cabe destacar que TweetEval y los modelos preentrenados asociados están disponibles en múltiples idiomas, incluyendo inglés, español, árabe y francés, entre otros, lo que amplía considerablemente su aplicabilidad a contextos multilingües como los analizados en este trabajo pues sabemos que existe una diferencia importante entre implementar un sistema que funcione para idiomas como el inglés (para el cual existen numerosos recursos lingüísticos y herramientas de análisis) y un sistema implementado para idiomas con pocas herramientas de este tipo, o uno que esté orientado a procesar datos de un gran conjunto de idiomas [Balahur, 2013]. De hecho, Twitter está disponible en más de 30 idiomas. Sin embargo, los usuarios “twitean” en más de 80 idiomas diferentes.

Por último, es importante señalar, no obstante, que Twitter no es una muestra representativa de la población general. Su base de usuarios presenta sesgos demográficos hacia perfiles más jóvenes, urbanos y con mayor nivel educativo [Mislove et al., 2011].

Esta limitación, que será discutida en mayor detalle en las conclusiones, debe tenerse en cuenta al interpretar los resultados y extraer conclusiones sobre el comportamiento del electorado en su conjunto.

1.3. Motivación

El uso de Twitter como fuente de datos y de los tweets como elementos con los que trabajar para entrenar y validar nuestros modelos nos lleva obligatoriamente a adoptar una serie de medidas para hacer frente a peculiaridades propias de textos tan informales como son los tweets [Balahur, 2013]:

- Los tweets son cortos, por lo general no ocupan más de 140 caracteres. En ellos, los usuarios son indicados con el signo “@” y los temas con el signo del hashtag

“#”.

- En muchas ocasiones, los tweets no tienen una estructura gramatical definida pues a menudo contienen faltas de ortografía y abreviaciones.
- Los tweets subjetivos, en los que los usuarios comentan sobre un evento, están fuertemente marcados por expresiones que conllevan sentimientos, ya sea en forma de palabras afectivas o mediante el empleo de modalidades específicas; por ejemplo, el uso de letras mayúsculas o signos de puntuación repetidos para enfatizar palabras específicas. La mayoría de las veces, estas palabras son las que portan la carga sentimental.
- El uso de *slang* específica y emoticonos.
- En muchas ocasiones, el tema que se discute en los tweets ya está claramente marcado mediante el uso de hashtags, por lo que no hay necesidad de emplear herramientas lingüísticas complejas para determinarlo.
- En eventos de gran relevancia, el ritmo de tweets por minuto que comentan o “retuitean” información supera la tasa de miles por minuto.
- Como ya hemos mencionado antes, Twitter está disponible en más de 30 idiomas. Sin embargo, los usuarios “twitean” en más de 80 idiomas. La información que contiene puede ser útil para obtener datos y actualizaciones, por ejemplo, sobre situaciones de crisis en tiempo real. Sin embargo, para poder beneficiarse de esto, un sistema que procese estos textos debe ser fácilmente adaptable a otros idiomas y debe funcionar en tiempo casi real.

Siguiendo con este último punto, transmitir y consumir información de eventos o crisis a través de las redes sociales tiene sus consecuencias. Twitter, en particular, se ha convertido en un escenario central donde candidatos, partidos y ciudadanos libran batallas discursivas que pueden tener un impacto directo en los resultados electorales. Sin embargo, este mismo espacio ha demostrado ser vulnerable a fenómenos de manipulación informativa, como la difusión sistemática de noticias falsas.

Tres casos de estudio han marcado un punto de inflexión en la comprensión de estos fenómenos. La campaña presidencial de Donald Trump en 2016, que reveló por primera vez el potencial de Twitter como instrumento de interferencia política [Bovet and Makse, 2019]; el referéndum del Brexit, celebrado ese mismo año en Reino Unido, que mostró cómo la polarización extrema en redes sociales y la formación de cámaras de eco podían fragmentar a una sociedad en torno a narrativas irreconciliables [Gorodnichenko et al., 2021] y, finalmente, las elecciones italianas de 2022 y el ascenso de Giorgia Meloni evidenciaron la evolución y sofisticación de estas técnicas.

Estos tres casos, distribuidos en un período de seis años y en contextos geopolíticos diferentes, ofrecen una oportunidad única para estudiar de forma comparativa cómo el sentimiento político se manifiesta en Twitter, cómo evoluciona a lo largo de una campaña y en qué medida refleja o anticipa los resultados electorales reales. A pesar de

su relevancia, no existe hasta la fecha un análisis comparativo sistemático de estos tres casos que aplique una metodología PLN estandarizada y reproducible, lo que constituye el principal vacío que este trabajo pretende cubrir.

La motivación de este TFM es, por tanto, doble. Por un lado, contribuir al conocimiento científico sobre el papel de las redes sociales en la política contemporánea mediante el desarrollo y aplicación de técnicas de análisis de sentimiento y detección de tópicos. Por otro, ofrecer una metodología replicable que pueda extenderse a otros contextos electorales, aprovechando la disponibilidad de datasets públicos y herramientas de PLN de acceso abierto como TweetEval.

2 Estado del arte

Como ya hemos mencionado anteriormente, el análisis de la opinión abarca múltiples tareas de clasificación que, aunque relacionadas, persiguen objetivos distintos. Las dos tareas más relevantes en el contexto del análisis político son el análisis de sentimiento (sentiment analysis) y la detección de postura (stance detection). En esta sección se presentan ambas tareas y se discuten sus diferencias.

2.1. Tareas de clasificación de opinión en Twitter

2.1.1. Sentiment Analysis (Análisis de Sentimiento)

Como ya hemos mencionado en la introducción, el análisis de sentimiento, que es nuestra principal tarea, tiene como objetivo identificar la polaridad afectiva expresada en un texto. En su formulación más habitual, clasifica el texto en tres categorías [Liu et al., 2019]:

- Positivo: Expresa emociones, opiniones o valoraciones favorables
- Negativo: Expresa emociones, opiniones o valoraciones desfavorables
- Neutral: No expresa carga emocional clara o presenta información objetiva.

Ejemplos de esta clasificación ternaria:

Tweet	Sentiment	Justificación
“¡Qué gran día para la democracia!”	Positivo	Emoción favorable
“Esto es un desastre absoluto”	Negativo	Emoción desfavorable
“Las elecciones se celebran el domingo”	Neutral	Información objetiva

Tabla 2.1: Ejemplos de análisis de sentimiento en Tweets

2.1.2. Stance Detection (Detección de Postura)

La detección de postura tiene como objetivo identificar la posición del autor respecto a un target específico (una persona, organización, tema o propuesta). Requiere definir explícitamente el target y clasifica el texto en tres categorías [Mohammad et al., 2016]:

- Favor: El texto expresa apoyo, acuerdo o valoración positiva hacia el target

- Against: El texto expresa rechazo, desacuerdo o valoración negativa hacia el target
- Neither: El texto no expresa una postura clara, es neutral respecto al target, o no menciona el target de forma relevante

Ejemplos de esta clasificación ternaria para el target = “Brexit”:

Tweet	Stance	Justificación
“Votar Leave es lo mejor para UK”	Favor	Apoya el Brexit
“El Brexit destruirá la economía británica”	Against	Se opone al Brexit
“Hoy se vota el referéndum del Brexit”	Neither	No toma postura

Tabla 2.2: Ejemplos de Postura (Stance) en Tweets sobre el Brexit

A diferencia del sentiment analysis, stance detection requiere contexto: el mismo tweet puede clasificarse de forma diferente según cuál sea el target especificado.

Este TFM se centra principalmente en el análisis de sentimiento.

Sin embargo, opcionalmente, se explorará la tarea de stance detection como análisis complementario, permitiendo identificar no solo el tono emocional de los tweets, sino también el posicionamiento específico de los usuarios respecto a candidatos o propuestas concretas. Esto es especialmente relevante en el caso del Brexit, donde el debate se articuló en torno a dos posiciones claramente definidas (Leave vs. Remain).

La combinación de ambas tareas ofrece una visión más completa del discurso político en Twitter:

- Sentiment analysis → ¿Cuál es el tono del debate? (positivo/negativo/neutral)
- Stance detection → ¿A favor o en contra de quién/qué? (favor/against/neither)

2.2. Enfoques en TSA

El TSA ha experimentado un crecimiento notable desde los primeros trabajos realizados a finales de la primera década del siglo XXI. Se identifican cuatro grandes enfoques en la literatura [Giachanou and Crestani, 2016]:

1. Enfoques basados en Aprendizaje Automático:

Los métodos de aprendizaje automático construyen clasificadores a partir de conjuntos de tweets etiquetados. El proceso típico consta de tres fases: recopilación y etiquetado de tweets, extracción de características, y entrenamiento del clasificador [Giachanou and Crestani, 2016].

Entre los algoritmos de aprendizaje automático más utilizados en TSA se encuentran el Naive Bayes, los Support Vector Machines (SVM) y la regresión logística.

Los SVM han demostrado consistentemente un rendimiento superior en tareas de clasificación de texto de alta dimensionalidad [Giachanou and Crestani, 2016].

2. Enfoques basados en Léxico:

Los métodos léxicos asignan una puntuación de sentimiento a un texto a partir de diccionarios de palabras etiquetadas con polaridad. Recursos como SentiWordNet [Esuli and Sebastiani, 2006] y el MPQA Opinion Corpus [Wilson et al., 2005] han sido ampliamente utilizados en TSA. La principal ventaja de estos enfoques es que no requieren datos de entrenamiento etiquetados; sin embargo, su principal limitación es la dificultad para adaptarse al lenguaje informal y en constante evolución de Twitter [Giachanou and Crestani, 2016].

3. Enfoques Híbridos:

Los enfoques híbridos combinan métodos de aprendizaje automático con léxicos de sentimiento para aprovechar las ventajas de ambos. Se ha demostrado que esta combinación mejora el rendimiento respecto a cada enfoque de forma individual, especialmente en contextos donde los datos etiquetados son escasos.

4. Deep Learning y Modelos de Lenguaje Preentrenados:

El desarrollo del Deep Learning ha supuesto una revolución en el TSA. Los modelos basados en redes neuronales recurrentes (LSTM) y, más recientemente, en arquitecturas Transformer han desplazado a los métodos clásicos en prácticamente todas las tareas de PLN.

El modelo BERT (Bidirectional Encoder Representations from Transformers) [Liu et al., 2019] marcó un punto de inflexión al introducir el preentrenamiento bidireccional sobre grandes corpus de texto. Su variante RoBERTa [Liu et al., 2019], con un preentrenamiento más robusto y sin la tarea de predicción de siguiente oración, mejoró aún más los resultados en tareas de clasificación de texto.

Para el dominio específico de Twitter, en [Nguyen et al., 2020] se desarrolló BERTweet, un modelo RoBERTa preentrenado sobre 850 millones de tweets en inglés. BERTweet ha demostrado rendimiento superior al de BERT y RoBERTa en múltiples tareas de TSA, incluyendo análisis de sentimiento, reconocimiento de entidades nombradas (NER) y etiquetado POS. Este modelo, junto con otros modelos específicos para Twitter, está disponible en la plataforma Hugging Face y es utilizado como base en el presente trabajo.

2.3. Enfoque en análisis de Tópicos: LDA

La detección automática de temas o tópicos en colecciones de texto es una tarea complementaria al análisis de sentimiento que permite identificar los principales focos de discusión en un corpus. El modelo de Latent Dirichlet Allocation (LDA), propuesto en [Blei et al., 2003], es el algoritmo más utilizado para esta tarea.

LDA es un modelo generativo probabilístico que asume que cada documento es una mezcla de tópicos y que cada tópico es una distribución de probabilidad sobre palabras. Su aplicación al análisis de campañas políticas en Twitter ha permitido identificar narrativas dominantes y su evolución temporal.

Sin embargo, LDA presenta limitaciones en el contexto de Twitter derivadas de la brevedad de los tweets. Para abordar este problema, investigadores se han propuesto técnicas de agrupación de tweets (tweet pooling) que mejoran la coherencia de los tópicos detectados al aumentar artificialmente la longitud de los documentos.

2.4. Preprocesamiento en Twitter

Una de las particularidades del TSA es la necesidad de un preprocesamiento específico para el formato de los tweets. En [Giachanou and Crestani, 2016] se identifican cuatro categorías principales de características relevantes para el TSA:

- Características semánticas: palabras de opinión extraídas de léxicos de sentimiento, negaciones.
- Características sintácticas: n-gramas, unigramas, bigramas, etiquetas POS. Los unigramas y los bigramas le dicen al modelo qué palabras deben ir solas o en pareja. Las etiquetas POS son las que le dicen al modelo cómo funcionan esas palabras. Por ejemplo, ayuda a distinguir entre “Voto (sustantivo)” y “Voto (verbo)”.
- Características estilísticas: emoticones, intensificadores, mayúsculas, puntuación.
- Características específicas de Twitter: hashtags, menciones, retweets, URLs.

El preprocesamiento estándar para modelos basados en Transformers, establecido en [Barbieri et al., 2020], incluye la normalización de menciones de usuario (@usuario → @USER) y de URLs (http://... → HTTPURL), manteniendo los hashtags y los emojis por su valor informativo.

2.5. Benchmarks y Evaluación: TweetEval

La evaluación estandarizada ha sido un reto persistente en el campo del TSA, ya que la diversidad de datasets y métricas dificultaba la comparación entre métodos. Para abordar esta limitación, Francesco Barbieri, Jose Camacho-Collados, Leonardo Neves y Luis Espinosa-Anke propusieron TweetEval [Barbieri et al., 2020], un benchmark unificado que agrupa siete tareas de clasificación de tweets bajo un marco de evaluación común.

Las siete tareas de TweetEval son:

- Reconocimiento de emociones
- Detección de odio (hate speech)

- Detección de ironía
- Clasificación de emojis
- Análisis de sentimiento
- Detección de ofensas
- Detección de postura (stance detection).

Para la tarea de análisis de sentimiento, TweetEval adopta los datos del SemEval-2017 Task 4 [Rosenthal et al., 2017], que clasifica tweets en tres categorías de polaridad: positivo, negativo y neutral. La métrica de evaluación principal es el F1-score macro, que trata equitativamente todas las clases independientemente de su frecuencia.

TweetEval está disponible públicamente a través de Hugging Face y ha sido ampliamente adoptado como referencia en la comunidad investigadora. Los modelos del estado del arte alcanzan un F1-macro de aproximadamente 72-75 % en la tarea de sentimiento [Barbieri et al., 2020], siendo RoBERTa-base el modelo con mejor rendimiento reportado en el benchmark original.

2.5.1. Estructura del benchmark y formato de los datos

Cada una de las correspondientes tareas tiene su propio directorio de datos de entrenamiento y test. La organización general es la siguiente:

```
tweeteval/  
├── README.md ...Documentación del benchmark  
├── TweetEval_Tutorial.ipynb ..Notebook con  
│   │ ejemplos  
├── datasets/ .....Datasets de las 7 tareas  
│   ├── sentiment/  
│   ├── stance/  
│   ├── emoji/  
│   ├── emotion/  
│   ├── hate/  
│   ├── irony/  
│   └── offensive/  
├── evaluation_script.py Script de evaluación  
│   │ oficial  
└── predictions/ .....Predicciones de ejemplo  
    │ (baseline)
```

Figura 2.1: Estructura de directorios y archivos del repositorio TweetEval.

El directorio `datasets/` contiene los datos etiquetados para cada una de las siete tareas. Cada subdirectorio sigue una convención de nomenclatura uniforme, con la excepción

de stance detection que presenta una estructura especial que se detallará más abajo. El directorio `predictions/` incluye las predicciones del modelo RoBERTa-base re-entrenado en Twitter, correspondiente al mejor sistema evaluado en el paper original [Barbieri et al., 2020] como ya hemos mencionado, que sirve como baseline de referencia para comparaciones.

En cuanto al dataset de sentiment, este contiene aproximadamente 59899 tweets distribuidos entre los conjuntos de entrenamiento, validación y test. Se trata del segundo dataset más grande del benchmark TweetEval (tras emoji prediction), lo que proporciona una base sólida para el entrenamiento de modelos supervisados.

Estructura de archivos y organización El directorio `datasets/sentiment/` sigue la estructura estándar de TweetEval:

```

datasets/sentiment/
├── train_text.txt ...Tweets de entrenamiento
├── train_labels.txt ..... Etiquetas de
    entrenamiento
├── val_text.txt ..... Tweets de validación
├── val_labels.txt .... Etiquetas de validación
├── test_text.txt ..... Tweets de test
├── test_labels.txt ..... Etiquetas de test
└── mapping.txt ..... Mapeo label_id a texto

```

Figura 2.2: Estructura interna de archivos para la tarea de Sentiment Analysis.

Cada uno de los archivos `_text.txt` contiene un tweet por línea, preservando el formato original sin aplicar ningún tipo de preprocesamiento. Esto incluye hashtags, menciones de usuario (en formato `@usuario`), URLs, emojis y cualquier otra característica propia del lenguaje de Twitter. Esta decisión de diseño permite que cada investigador aplique las técnicas de preprocesamiento que considere más apropiadas para su metodología.

Los archivos `_labels.txt` contienen una etiqueta numérica por línea, con correspondencia directa línea a línea respecto a los archivos de texto. Es decir, la etiqueta en la línea `n` del archivo `train_labels.txt` corresponde al tweet en la línea `n` del archivo `train_text.txt`.

En cuanto al formato de los datos y la codificación de las etiquetas para sentiment, el archivo `mapping.txt` establece la correspondencia entre los identificadores numéricos de las etiquetas y sus categorías semánticas:

- 0. negative
- 1. neutral
- 2. positive

Por su lado, el dataset completo para stance contiene aproximadamente 4163 tweets, lo que lo convierte en uno de los conjuntos de datos más pequeños del benchmark TweetEval.

A diferencia del resto de tareas de TweetEval, la detección de postura presenta una organización jerárquica basada en temas o targets específicos. Esto refleja la naturaleza intrínseca de la tarea: la postura siempre se define respecto a algo o alguien. Los temas de los que dispone la tarea para stance son:

```

datasets/stance/
├── abortion/ .....Tópico: Aborto (~933 tweets)
│   ├── train_text.txt
│   ├── train_labels.txt
│   ├── val_text.txt
│   ├── val_labels.txt
│   ├── test_text.txt
│   └── test_labels.txt
├── atheism/ .....Tópico: Ateísmo (~733 tweets)
│   └── ..... Misma estructura de archivos de texto y etiquetas
├── climate/ .....Tópico: Cambio climático (~564 tweets)
│   └── ...
├── feminist/ ..... Tópico: Movimiento feminista (~949 tweets)
│   └── ...
├── hillary/ ..... Tópico: Hillary Clinton (~984 tweets)
│   └── ...
└── mapping.txt .. Mapeo de etiquetas compartido (0: Against, 1:
    Favor, 2: None)

```

Figura 2.3: Organización jerárquica del dataset para la tarea de Stance Detection por tópicos.

Cabe mencionar que los cinco targets incluidos en TweetEval corresponden a temas políticamente polarizantes en el contexto estadounidense durante el período 2015-2016, aunque el debate alrededor de muchos de ellos actualmente sigue siendo relevante:

- Abortion (aborto): Debate sobre el derecho al aborto
- Atheism (ateísmo): Postura respecto a la religión y el ateísmo
- Climate change (cambio climático): Posicionamiento sobre la crisis climática
- Feminist movement (feminismo): Opiniones sobre el movimiento feminista
- Hillary Clinton: Postura específica respecto a la candidata presidencial.

Es importante destacar que el target “Hillary Clinton” es el único referido a una persona concreta, mientras que los demás corresponden a temas ideológicos. Esta heterogeneidad permite evaluar la capacidad de los modelos para generalizar la detección de postura tanto a entidades como a conceptos abstractos.

La distribución de tweets entre los diferentes targets es desigual, reflejando posiblemente la popularidad o controversia de cada tema en Twitter durante el período de recolección:

Target	Train + Val + Test	Observaciones
Hillary Clinton	~984	Mayor volumen, tema muy polarizante
Feminist movement	~949	Alto engagement en redes sociales
Abortion	~933	Debate perenne en política estadounidense
Atheism	~733	Menor volumen de conversación
Climate change	~564	El más pequeño del conjunto

Tabla 2.3: Distribución de muestras y observaciones por target para stance detection

Esta variabilidad en el tamaño de los conjuntos de datos por target es una característica intrínseca del benchmark y debe tenerse en cuenta al entrenar modelos, especialmente si se pretende generalizar a través de múltiples targets.

En cuanto al formato, a diferencia de la estructura descentralizada por targets, el archivo mapping.txt es único y compartido por todos los subdirectorios:

- 0. none
- 1. against
- 2. favor

Debemos mencionar que el proceso de etiquetado de postura es inherentemente más complejo que el de sentimiento, ya que requiere: identificación del target, comprensión contextual para captar sarcasmo, ironía o referencias indirectas y evaluación de la intención del tweet. Es por eso que las métricas de rendimiento para las tareas de postura suelen ser inferiores a las de análisis de sentimiento.

Siguiendo con el tema de la evaluación, TweetEval proporciona un script de Python (evaluation_script.py) que implementa el protocolo de evaluación oficial del benchmark. Este script calcula las métricas apropiadas para cada tarea y reproduce exactamente los resultados reportados en el paper original. El script espera archivos de predicción con el mismo formato que los archivos _labels.txt.

De hecho, la carpeta predictions, que se puede ver en el esquema de la estructura, contiene las predicciones generadas por el modelo RoBERTa-base re-entrenado en 58 millones de tweets y del que hablaremos con más detalle en la sección de fundamentos teóricos. Estas predicciones sirven como baseline de referencia para comparaciones y corresponden al mejor modelo evaluado en [Barbieri et al., 2020].

Según los resultados reportados en el benchmark:

Tarea	F1-macro (%)	Modelo
Sentiment Analysis	71.3	RoBERTa-base
Sentiment Analysis	72.8	RoBERTa-Retrained
Stance Detection	68.0	RoBERTa-base
Stance Detection	69.3	RoBERTa-Retrained

Tabla 2.4: Resultados de F1-macro por Tarea y Modelo

2.5.2. Análisis exploratorio de los datos

Con la estructura del benchmark clara podemos explorar un poco más los datos para saber bien cómo se distribuyen en los dos conjuntos de sentimiento y stance.

El conjunto de datos de sentimiento de TweetEval consta de 59.899 tweets distribuidos en tres particiones: entrenamiento (45.615), validación (2.000) y test (12.284). La Figura 2.4 muestra la distribución de las tres clases (negativo, neutro y positivo) en cada partición.




Figura 2.4: Distribución de clases por split en el dataset de Sentiment Analysis.

El primer aspecto destacable y que ya hemos mencionado anteriormente es el desequilibrio de clases, que afecta de forma diferente a cada partición. En entrenamiento y validación, la clase dominante es la neutra (45,3 % y 43,5 % respectivamente), seguida de la positiva (39,1 % y 40,9 %) y, muy por detrás, la negativa (15,5 % y 15,6 %).

En cuanto a la longitud de los tweets, la Figura 2.5 muestra que la mayoría oscila entre 15 y 25 tokens, con una longitud media de 19,2 tokens en entrenamiento y un percentil 95 de 27 tokens. El conjunto de test presenta una longitud media ligeramente inferior (14,9 tokens), coherente con el hecho de que incluye tweets más variados, algunos de los cuales corresponden a periodos anteriores con el límite de 140 caracteres más restrictivo. El problema es que como las 3 clases siguen la misma distribución, aproximadamente normal, la longitud de los tweets no nos va a servir como feature discriminativo.




Figura 2.5: Distribución de longitud de los tweets en el conjunto de entrenamiento en el dataset de Sentiment Analysis.

En las figuras 2.6 y 2.7 mostramos respectivamente el top 15 tokens más frecuentes diferenciando por clase y eliminando stopwords, y el top 20 hashtags más frecuentes.




Figura 2.6: Tokens más frecuentes en el dataset separando por clase.




Figura 2.7: *Hashtags* más frecuentes en el dataset de sentimiento.

En el caso de los tokens, se aprecia que dominan las palabras propias del preprocesamiento, como *user* que sería el resultado de la anonimización del usuario correspondiente, o *u002c* que es la coma en formato Unicode. Esto pone de manifiesto que convendría limpiar el dataset.

Por otro lado, en las 3 clases hay presencia de palabras relacionadas con el tiempo, como los días de la semana, *sunday*, *friday*, *night*, *day*, *tomorrow*, *saturday*, *may*, *time* ... También hay palabras exclusivas de la clase positiva, como *good*, *love*, pero no exclusivas de la clase negativa.

En el caso de los hashtags, *#raw*, *#mtvstars*, *#summerslam*, *#wwe*, *#mlb* y *#cubs* nos hacen pensar que el corpus es mayoritariamente de deporte y entretenimiento, no político. Solo aparece *#gopdebate* (que hace referencia al debate sobre el *Grand Old Party* americano, es decir, el partido republicano) y *#tcot* (acrónimo para *Top Conservatives On Twitter*). Para aplicación electoral va a haber un hueco de dominio significativo que tendremos que solventar de alguna forma.

Paralelamente, hemos realizado otro EDA a partir de otro notebook de Jupyter para el dataset de detección de postura y también hemos podido extraer varias conclusiones.




Figura 2.8: Distribuciones porcentuales a favor/neutral/en contra para los distintos tópicos del dataset

Como muestra la Figura 2.8, en 4 de los 5 tópicos la mayoría del dataset se muestra en contra, a excepción del cambio climático, donde la mayoría se muestra a favor (entendemos este a favor como “a favor de que es un problema real, existe y no se puede ni debe negar”).

Hemos estudiado la distribución por clase en el split train-val-test y nos hemos dado cuenta de que el conjunto de validación es muy pequeño para todos los tópicos, de entre 40 y 70 muestras. Esto nos indica que va a hacer falta aplicar algún método de combinación entre el conjunto de validación y el de test o usar la validación cruzada para así evitar la alta varianza en los resultados. Para todos los tópicos, no obstante, las distribuciones son muy similares.




Figura 2.9: Distribuciones del split para los distintos tópicos del dataset de Stance Detection.

En cuanto a la longitud de los tweets, no varían especialmente, de media, en función del tópico y, en general, los tweets se siguen manteniendo en una media de extensión de entre 15 y 20 tokens, similar a lo que pasaba en el dataset de sentimiento.




Figura 2.10: Longitud de los tweets para los distintos tópicos del dataset de Stance.

Por último, y en relación al vocabulario empleado en los tweets de este dataset, cabe destacar que sí que hay presencia de vocabulario específico para los distintos tópicos, por lo que esas palabras sí que podrían utilizarse como una feature específica y discriminadora a la hora de clasificar usando los modelos de lenguaje. Destacan:

- Abortion: abortion, life, women, babies, unborn
- Atheism: god, jesus, lord, believe, religion

- Climate Change: climate, change, global, world
- Feminis: women, men, feminist, #gamergate
- Hillary Clinton: hillary, clinton, vote, #wakeupamerica, #tcot

No obstante, también hay tokens que se repiten a lo largo de todos los temas, como el mencionado anteriormente *user*, y, de nuevo, palabras temporales como *now*, *when*, *there*.




Figura 2.11: Top 12 tokens más frecuentes para los tweets de los distintos tópicos del dataset de Stance.

Cabe destacar que el token más repetido en todos los tópicos es el hashtag #semst, que hace referencia a SemEval Stance Task (SemEval-2016 Task 6). Los creadores del dataset recolectaron tweets buscando #semst junto con términos del topic (abortion, hillary, etc.). Es un hashtag de colección metodológica pues los usuarios lo añadían para participar en debates cuyo contenido luego se anotó manualmente para el benchmark.

Para no confundir a los modelos de lenguaje y asegurarnos de que realmente usen el vocabulario específico para clasificar, debemos añadir semst a stopwords antes de tokenizar o entrenar.

3 Fundamentos teóricos

3.1. Arquitecturas de modelos de lenguaje

Los modelos con mejores resultados en la tarea de clasificación de sentimiento (según literatura) y que hemos mencionado brevemente en el estado del arte son los siguientes:

Modelo	F1-Macro	Fuente	Disponibilidad
twitter-roberta-base-sentiment	~72.8 %	[Barbieri et al., 2020]	Hugging Face
BERTweet-base	~71.5 %	[Nguyen et al., 2020]	Hugging Face
RoBERTa-base (genérico)	~70.2 %	[Liu et al., 2019]	Hugging Face
BERT-base	~68.5 %	[Devlin et al., 2019]	Hugging Face

TABLA 3.1: Comparativa de rendimiento F1-Macro entre modelos basados en Transformers para Sentiment Analysis.

El desarrollo de modelos de lenguaje basados en arquitecturas de Deep Learning ha revolucionado el campo del PLN en los últimos años. En esta sección se presentan los conceptos fundamentales detrás de las arquitecturas utilizadas en este trabajo.

3.1.1. Transformers

En el paper original que propuso inicialmente esta arquitectura, el transformer permitía realizar la traducción de un idioma a otro con la gran ventaja de poder entrenar al modelo en paralelo; lo que aumentaba drásticamente la velocidad y reducción del coste; y utilizando como potenciador el mecanismo de atención. Asimismo, permite que la red tenga memoria total: cada palabra del texto tiene acceso a las demás. Esto elimina el problema que presentaban las redes usuales de la memoria limitada, que hace que, en frases o textos muy largos, la red se vaya olvidando de las palabras del principio.

Con el tiempo, esta arquitectura resultó ser flexible y se pudo utilizar para tareas más allá del PLN, además de para la generación de texto, clasificación y resumen de contenidos, también pudo traspasar esa frontera y ser aplicado en Visión Artificial, Generación de Audio, Predicción de Series Temporales y Aprendizaje por Refuerzo.

De hecho, en los últimos años los Transformers han desplazado por completo a las Redes Neuronales Recurrentes (RNN) y a las redes convencionales en PLN, y para entender por qué debemos diseccionar su arquitectura. A diferencia de una red neuronal usual (como un Perceptrón Multicapa o MLP), el Transformer no trata los datos como una secuencia rígida ni como puntos independientes, sino como un grafo de relaciones.

La arquitectura general de un transformer es como sigue:




Figura 3.1: Arquitectura general del transformer. Adaptado de pTRANSFORMERS

Si nos fijamos en la Figura 3.1, podemos ver que hay 2 partes bien diferenciadas de la arquitectura. La caja de la izquierda, que se correspondería con el Encoder, y la caja de la derecha, que se correspondería con el Decoder. En su interior tanto Encoder como Decoder cuentan con un componente de Atención (o dos) y una red neuronal “normal” como salidas. Cabe destacar que para tareas de clasificación de sentimiento, como en nuestro caso, se suele utilizar únicamente el bloque Encoder.

Así, el corazón del Transformer es el Scaled Dot-Product Attention. Matemáticamente, se define mediante tres matrices: Queries (Q), Keys (K) y Values (V), derivadas de la entrada X mediante pesos aprendidos.

La salida de la atención se calcula como:

$$Attention(Q, K, V) = softmax(\frac{Q \cdot K^T}{\sqrt{d_k}})V$$

donde d_k es la dimensión de las claves o la dimensión de cada cabeza de atención. El factor $\frac{1}{\sqrt{d_k}}$ previene que el producto escalar crezca excesivamente, lo que causaría gradientes pequeños en la función softmax.

El mecanismo de atención nos ayuda a crear y dar fuerza a las relaciones entre palabras en una oración.

Mirando de nuevo la Figura 3.1, podemos ver que en el momento de entrenar, estamos pasando el Input (que podría ser la frase a traducir o el twit que nos interesa clasificar en nuestro caso) y el Output (que podría ser la traducción del input o la etiqueta de sentimiento de nuestro twit) al mismo tiempo al modelo.

Tradicionalmente, usamos la salida únicamente para “validar” el modelo y ajustar los pesos de la red neuronal (durante el backpropagation). Sin embargo en el Transformer estamos usando la salida como parte del aprendizaje que realiza el modelo mediante una técnica llamada **Teacher Forcing**.

Entonces, es por eso que el output es también la entrada del Decoder hacia embeddings, posicionamiento y el ingreso a la Masked Self Attention que comentaremos a continuación.

Además, cabe destacar que hay 3 tipos de atención distinta:

1. Self-Attention.
2. Cross-Attention.
3. Masked-Attention.

Self-Attention se refiere que crearemos los valores y las matrices de Q,K,V a partir de las propias entradas de los tokens de entrada.

En la Atención Cruzada, vemos cómo utilizamos como entradas en el Decoder los valores obtenidos en el Encoder. Esto es lo que hará que con sólo el valor (V) del Output pueda modelar la salida de atención buscada.

Y la llamada Masked-Attention se refiere a que enmascaramos la parte triangular superior de la matriz de atención al calcularla para no caer en “data-leakage”, es decir, para no “adelantar información futura” que el output no debería tener en su momento. En el Encoder, cuando tenemos los valores de entrada y hacemos self-attention, calculamos la atención de “todos contra todos” porque todos los tokens de entrada son conocidos desde el principio, pero cuando vamos produciendo el output y vamos escribiendo la cadena palabra por palabra, se supone que no podemos conocer el contenido de las palabras que aún no han sido generadas.



Figura 3.2: Resultado de la enmascaración de la matriz $Q \cdot K$ para una frase de ejemplo. Adaptado de [Pérez, 2020]

Para entender más en profundidad la arquitectura de estas redes, viene bien entender de qué otras capas está formada y cómo se van sucediendo. Las capas del transformer son:

a) Capa de Self-Attention Multi-Cabeza:

Cada palabra genera 3 vectores: Query (Q), Key (K) y Value (V). Se mide la afinidad entre Q y K de todas las palabras para decidir cuánto valor (V) aportar a la representación final. El modelo realiza este proceso en paralelo varias veces para capturar distintas relaciones o dimensiones.

b) Capa Forward:

Tras la atención, cada posición pasa por una red neuronal densa idéntica. Lo revolucionario es que esta capa se aplica a cada palabra de forma independiente y en paralelo, lo que permite aprovechar el rendimiento de la GPU. Su función es procesar la información capturada por la atención y proyectarla a un espacio de mayor dimensionalidad.

c) Capas de normalización y conexiones residuales:

Entre cada subcapa hay una conexión residual ($x + \text{Sublayer}(x)$). Esto permite que el gradiente fluya sin desvanecerse durante el entrenamiento de modelos muy profundos, evitando que la información original se pierda en el ruido de las transformaciones. La normalización previene que el rango de valores entre capas cambie “demasiado bruscamente” logrando hacer que el modelo entrene más rápido y con mayor capacidad de generalización.

d) Capa lineal y Softmax final:

La salida final del modelo pasa por una última capa Lineal y el Softmax. El Softmax nos dará un valor de entre 0 y 1 para cada una de las posibles palabras (tokens) de salida. Entonces si nuestro lenguaje total es de 50.000 posibles tokens (incluyendo signos de puntuación, admiración, interrogación), encontraremos a uno de ellos con valor más alto, que será la predicción final.

La parte más novedosa que introducen los transformers al campo del PLN es el **positional encoding** a los embeddings en los que convierte las palabras del input.

El positional encoding sirve para especificarle al modelo en qué orden o posición van los tokens que le pasamos. Porque está claro que, en el procesamiento de textos en particular, el orden de las palabras es crucial pues puede cambiar por completo el significado de la frase. No es lo mismo decir “el perro mordió al papá del niño”, que “el perro del niño mordió al papá”.

Para resolver esto, se agrega una valor secuencial al embedding que se asume que la red podrá interpretar. Si aparece el token “perro” como segunda palabra ó como décima, mantendrá en esencia el mismo vector semántico pero con un ligero valor adicional que lo distinguirá y que será el que le de la pista a la red neuronal de interpretar su posición en la oración.

Los creadores del Transformer propusieron utilizar funciones trigonométricas de diferentes frecuencias. La fórmula para una posición pos y una dimensión i del vector es:

$$PE_{(pos,2i)} = \sin\left(\frac{pos}{10000^{2i/d_{model}}}\right)$$

$$PE_{(pos,2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{model}}}\right)$$

donde d_{model} representa la dimensión del modelo o el tamaño de la representación oculta.

Así, aunque el Transformer original fue concebido inicialmente para traducción (Encoder-Decoder) tal y como hemos mencionado antes, la tarea de análisis de sentimiento se beneficia principalmente de la capacidad del Encoder para generar representaciones ricas del contexto. Esto dio lugar a la familia de modelos pre-entrenados que son de los que vamos a hablar a continuación.

3.1.2. BERT: *Bidirectional Encoder Representations from Transformers*

Fue desarrollado por Google en 2018. Hoy en día, hay muchas versiones de BERT pre-entrenadas, pero en el artículo original, Google entrenó dos versiones de BERT: BERT-base y BERT-large con diferentes arquitecturas neuronales.

En esencia, BERTbase se desarrolló con 12 capas de transformación, 12 capas de atención y 110 millones de parámetros, mientras que BERTlarge utilizó 24 capas de transformación, 16 capas de atención y 340 millones de parámetros. Como era de esperar, BERTlarge superó a su hermano pequeño en las pruebas de precisión [DataCamp, 2024].

BERT supuso un cambio de paradigma al eliminar la restricción de lectura de izquierda a derecha de los modelos anteriores.

Mientras que los modelos autorregresivos maximizan la probabilidad de una palabra dado su contexto izquierdo $P(w_i|w_1, w_2, \dots, w_{i-1})$, BERT utiliza el Masked Language Model (MLM). En este proceso, se enmascara aleatoriamente un porcentaje de los tokens de entrada (usualmente el 15 %) y el modelo debe predecirlos utilizando el contexto tanto a la izquierda como a la derecha simultáneamente.

Al enmascarar una palabra de una frase, esta técnica obliga al modelo a analizar las palabras restantes en ambas direcciones de la frase para aumentar las posibilidades de predecir la palabra enmascarada. El MLM se basa en técnicas ya probadas en el campo de la visión por ordenador, y es estupenda para tareas que requieren una buena comprensión contextual de toda una secuencia DataCamp [2024].

Así, formalmente, si x es una secuencia y $\hat{x}$ es su versión enmascarada, BERT minimiza la pérdida de entropía cruzada:

$$L_{LML} = -\mathbb{E}_{x \sim D} \sum_{i \in m} \log(P(x_i | \hat{x}))$$

donde m es el conjunto de índices de los tokens enmascarados y la esperanza $\mathbb{E}_{x \sim D}$ (de que el tweet x sea aleatoriamente escogido del dataset D) indica que o que nos importa es el promedio de error en todo el conjunto de datos. Es decir, que La pérdida total del modelo (L) es el promedio negativo de los aciertos del modelo sobre todos los tweets (x) que existen en D .

A diferencia de una métrica rígida como el Accuracy (donde o aciertas o fallas), la Entropía Cruzada es derivable. Esto permite que el modelo sepa qué tan lejos se ha quedado de la verdad. No es lo mismo fallar por poco (darle un 40

Esta bidireccionalidad profunda es crítica en Twitter para entender sarcasmos o negaciones que dependen de palabras situadas al final de la oración.

Algunas de las variantes más conocidas del modelo BERT, desarrolladas gracias a la naturaleza de código abierto de este son:

- **RoBERTa:** Abreviatura de *Robustly Optimized BERT Approach*, RoBERTa es una variante de BERT creada por Meta en colaboración con la Universidad de Washington. Considerada una versión más potente que el BERT original, RoBERTa se entrenó con un conjunto de datos 10 veces mayor que el utilizado para entrenar el BERT. En cuanto a su arquitectura, la diferencia más significativa es el uso del aprendizaje de enmascaramiento dinámico en lugar del aprendizaje de enmascaramiento estático. Esta técnica, que consistía en duplicar los datos de entrenamiento y enmascararlos 10 veces, cada vez con una estrategia de enmascaramiento distinta, permitió a RoBERTa aprender representaciones más robustas y generalizables de las palabras [DataCamp, 2024].

Asimismo, se demostró que la tarea de *Next Sentence Prediction* (predecir si una frase sigue a otra) no aportaba valor significativo y se eliminó para centrar la capacidad del modelo en el lenguaje. Como última diferencia con el BERT original, mencionar que utiliza una versión de *Byte-Pair Encoding* (BPE), del que hablaremos más en profundidad y que trabaja con bytes en lugar de caracteres Unicode, lo que permite manejar un vocabulario más amplio y reducir los tokens desconocidos ([UNK]).

- **BERTweet: Especialización en el dominio de Twitter:** Como se observa en la Tabla 3.1, los modelos específicos para Twitter suelen superar a los genéricos.

BERTweet es el primer modelo de lenguaje a gran escala pre-entrenado específicamente para tweets en inglés (o multilingüe según la versión).

La diferencia fundamental reside en su corpus de entrenamiento (850M de tweets) y en su pre-procesamiento. Mientras que BERT se entrena con Wikipedia, BERTweet aprende la semántica de elementos propios de la red social:

- **Manejo de entidades:** Mejor comprensión de @usuarios, #hashtags y URLs.
 - **Emojis:** Los embeddings de BERTweet están diseñados para capturar la carga sentimental de los emojis, que en Twitter actúan como modificadores críticos del sentimiento.
- **DistilBERT:** Desde el lanzamiento de los primeros LLM a finales de la década de 2010, se ha consolidado la tendencia a construir LLM más grandes y pesados, tal y como se observa en la Figura 3.4. Esto tiene sentido, ya que parece haber una relación directa entre el tamaño del modelo y su precisión. Sin embargo, también es cierto que cuanto mayor es el modelo, más recursos necesita para funcionar y, por tanto, menos gente puede permitirse utilizarlo. DistilBERT pretende hacer más accesible el BERT ofreciendo una variante más pequeña, rápida, barata y ligera. Basándose en la arquitectura del BERT original, DistilBERT utiliza técnicas de destilación de conocimientos durante el preentrenamiento para reducir el tamaño en un 40 %, conservando el 97 % de sus capacidades de comprensión del lenguaje y siendo un 60 % más rápido.

Así, DistilBERT surge como una alternativa ligera mediante una técnica denominada Knowledge Distillation (Destilación de Conocimiento), basada en el popularmente conocido método de entrenamiento de profesor-alumno, donde un modelo pequeño (el Alumno) aprende a imitar el comportamiento de un modelo grande y pre-entrenado (el Profesor, en este caso BERT-base). De esta forma, en lugar de entrenar al alumno solo con las etiquetas reales (0 o 1), se le entrena para que su salida sea idéntica a la distribución de probabilidad del profesor. Esto es crucial porque el profesor “sabe” que una palabra puede ser un 90 % probable, pero otra palabra similar tiene un 8 % y una errónea un 2 %. Esa “incertidumbre rica” es lo que el alumno hereda.

Para lograr esto, se añade una componente de pérdida de destilación $L_{distill}$ a la función de entrenamiento, que se calcula usando la Divergencia de Kullback-Leibler (KL), para la que se cogen las predicciones del profesor con $T > 1$ y las predicciones del alumno con $T > 1$:

$$L_{distill} = \sum_i t_i \log(s_i)$$

donde t son las soft targets (las probabilidades del profesor) y s las del alumno. Para suavizar estas probabilidades y que el alumno aprenda mejor las relaciones sutiles, se utiliza un hiperparámetro llamado Temperatura (T) en la función Softmax, de forma que, si T es alta, la distribución es más “suave”, revelando qué palabras

considera el profesor que son “casi correctas”:

$$y_i(x|T) = q_i = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)}$$




Figura 3.3: Entrenamiento de destilación, para el que no se usa el conjunto de entrenamiento entero sino un conjunto conocido como “transfer set”. Adaptado de [Mohan, 2022]

Así, la función de pérdida total se calcula como la suma:

$$L_{total} = (\alpha \cdot L_{student}) + ((1 - \alpha) \cdot L_{distill})$$

donde $\alpha \in [0, 1]$ es un factor de peso, y donde $L_{student}$ representa el error del modelo alumno al intentar predecir los datos reales. Se trata de la pérdida de MLM.

Volviendo al BPE o Byte-Pair Encoding, este nos ayuda a entender cómo estos modelos procesan el “slang” y los errores ortográficos, crucial para nuestra tarea en cuestión.

En particular, el gran desafío de Twitter es el problema de las Palabras Fuera de Vocabulario (OOV - Out Of Vocabulary). En un modelo tradicional, si el usuario escribe “bueníiiiiimo”, el modelo lo marca como un token desconocido ([UNK]), perdiendo toda la carga semántica. BPE soluciona esto mediante una segmentación por sub-unidades (subwords).

El algoritmo del BPE no se basa en reglas lingüísticas (como separar prefijos o sufijos), sino en estadística pura. El proceso de construcción del vocabulario sigue estos pasos:

1. Inicialización: Se descompone todo el corpus de entrenamiento en caracteres individuales. El vocabulario inicial son todos los caracteres únicos presentes (letras, números, emojis).

2. Identificación de pares: Se cuenta la frecuencia de todos los pares de tokens adyacentes.
3. Fusión (Merge): El par más frecuente (u,v) se fusiona en un nuevo token único uv . Este nuevo token se añade al vocabulario.
4. Iteración: Se repite el proceso hasta alcanzar un tamaño de vocabulario predefinido (por ejemplo, 50,000 unidades en RoBERTa).

La versión que utilizan RoBERTa y BERTweet del BPE es una evolución llamada Byte-level BPE, donde, en lugar de empezar con caracteres Unicode (que pueden ser miles, incluyendo todos los alfabetos y emojis), el algoritmo empieza con los 256 bytes posibles. Esto garantiza que el vocabulario base sea minúsculo (256 unidades) y que cualquier cadena de texto (incluyendo emojis complejos o caracteres especiales de Twitter) pueda ser representada sin generar nunca un token [UNK].

BPE optimiza una función de coste implícita, pues si el vocabulario es muy pequeño (solo caracteres), las secuencias son muy largas y el modelo tiene dificultades para captar relaciones a larga distancia (la atención se dispersa), mientras que si el vocabulario es muy grande (palabras completas), la matriz de embeddings es inmanejable y hay mucha dispersión (sparsity). Así, el BPE encuentra el punto donde los tokens más frecuentes son palabras completas y los menos frecuentes son fragmentos con significado (morfemas), lo cual es ideal para la naturaleza ruidosa y creativa del lenguaje en Twitter.

Matemáticamente hablando, podemos verlo como que el BPE intenta minimizar la longitud de la secuencia de tokens manteniendo un vocabulario V manejable. Se puede ver como una búsqueda de la longitud de descripción mínima:

$$\min_V \left(\sum_{x \in D} |T(x, V)| \right)$$

donde D es el corpus de tweets; V , el vocabulario o tokens permitidos y $|T(x, V)|$ el número de tokens en los que se divide el tweet x usando el vocabulario V .

En la siguiente imagen podemos ver algunos de los modelos más famosos basados en transformers.




Figura 3.4: Evolución cronológica de los Modelos de Lenguaje basándose en su número de parámetros (en millones). Se observa una tendencia exponencial hacia modelos de gran escala, contrastando con versiones destiladas (DistilBERT) que buscan la eficiencia, lo cual en ocasiones puede ser clave para tareas de análisis en tiempo real, donde la inmediatez es lo primordial. Adaptado de [Pérez, 2020]

Por último, mencionar que el BERT y sus variantes vienen con las limitaciones y problemas tradicionales asociados a los LLM. Las predicciones del BERT se basan siempre en la cantidad y calidad de los datos utilizados para su entrenamiento. Si los datos de entrenamiento son limitados, pobres y sesgados, el BERT puede arrojar resultados inexactos, perjudiciales o incluso las llamadas alucinaciones LLM [DataCamp, 2024].

3.1.3. Modelado de tópicos: el LDA

EL LDA es una aproximación bayesiana al modelado de tópicos, basado en probabilidades condicionadas. Para el LDA cada tweet es una mezcla de tópicos y cada tópico es una mezcla de palabras. Es un modelo “latente” porque los tópicos no están explícitos, sino que el algoritmo los infiere a partir de la co-ocurrencia de palabras

3.2. Métricas de evaluación

La evaluación de los modelos de clasificación de sentimiento y detección de postura requiere el uso de métricas estandarizadas que permitan cuantificar su rendimiento y compararlo con el estado del arte. En esta sección se presentan las métricas utilizadas en este trabajo.

3.2.1. Métricas Básicas de Clasificación

Para entender las métricas de evaluación empleadas, es necesario introducir primero los conceptos básicos de matriz de confusión. Para una tarea de clasificación binaria (por ejemplo, positivo vs. negativo, o clase 0 vs. clase 1), la matriz de confusión contabiliza:

- TP (True Positives): Instancias positivas correctamente clasificadas como positivas.
- TN (True Negatives): Instancias negativas correctamente clasificadas como negativas
- FP (False Positives): Instancias negativas incorrectamente clasificadas como positivas
- FN (False Negatives): Instancias positivas incorrectamente clasificadas como negativas

Estas relaciones se organizan visualmente en una matriz de confusión, como se muestra en la Tabla 3.2:

		Valor Predicho	
		Positivo	Negativo
Valor Real	Positivo	TP	FN
	Negativo	FP	TN

Tabla 3.2: Estructura de la matriz de confusión para clasificación binaria.

A partir de estos valores se calculan las métricas fundamentales:

- **Precisión**

Mide la proporción de predicciones positivas que fueron correctas:

$$\text{Precision} = \frac{TP}{TP + FP}$$

- **Recall (Exhaustividad)**

Mide la proporción de instancias positivas reales que fueron detectadas:

$$\text{Recall} = \frac{TP}{TP + FN}$$

- **F1-Score**

Es la media armónica de precision y recall, proporcionando un balance entre ambas:

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

- **Accuracy (Exactitud)**

Proporción de predicciones correctas sobre el total:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

3.2.2. F1-Score Macro: Métrica Principal

En tareas de clasificación multi-clase, como el análisis de sentimiento con tres categorías (positivo, negativo, neutral), existen diferentes formas de agregar las métricas de cada clase:

- F1-Micro: Calcula métricas globales agregando TP, FP y FN de todas las clases
- F1-Macro: Calcula el F1 de cada clase por separado y luego promedia
- F1-Weighted: Promedio ponderado por el número de instancias de cada clase Para este trabajo se utiliza el F1-Score Macro como métrica principal, siguiendo el estándar establecido por TweetEval [Barbieri et al., 2020]. El F1-macro se calcula como:

$$F_1^{\text{macro}} = \frac{1}{C} \sum_{i=1}^C F_1^i$$

donde C es el número de clases y F_1^i es el F1-score de la clase i .

El F1-Macro trata todas las clases equitativamente, independientemente de su frecuencia en el dataset. Penaliza el rendimiento pobre en clases minoritarias, evitando que modelos sesgados hacia la clase mayoritaria obtengan puntuaciones artificialmente altas. Además, es más informativo que la accuracy en datasets desbalanceados, que es el caso habitual en análisis de sentimiento político donde la clase neutral suele ser minoritaria.

Por ejemplo, en un dataset con distribución 70 % positivo, 20 % negativo, 10 % neutral, un clasificador que predice siempre “positivo” tendría 70 % accuracy pero $F1\text{-macro} = 23\%$ F1-macro refleja mejor la capacidad real del modelo para discriminar entre clases.

3.2.3. F1-Average para Stance Detection

Para la tarea de detección de postura (stance detection), se adopta la métrica definida en SemEval-2016 Task 6 [Mohammad et al., 2016]. En esta tarea, los tweets se clasifican en tres categorías respecto a un target (candidato, tema):

- Favor: El tweet apoya al target
- Against: El tweet se opone al target

- Neither: El tweet es neutral o no expresa una postura clara.

Sin embargo, desde el punto de vista del análisis político, las clases de mayor interés son Favor y Against, ya que representan posicionamientos claros. Por este motivo, [Mohammad et al., 2016] definieron la métrica F1-average como:

$$F_1^{\text{avg}} = \frac{F_1^{\text{favor}} + F_1^{\text{against}}}{2}$$

Esta métrica excluye la clase “Neither” del cálculo, concentrando la evaluación en la capacidad del modelo para distinguir entre posturas a favor y en contra. Esto es especialmente relevante en campañas electorales, donde el objetivo es identificar el apoyo u oposición hacia candidatos específicos, más que detectar tweets neutrales [Mohammad et al., 2016].

El uso del F1-avg nos va a permitir enfatizar las clases de mayor interés analítico (favor/against), evitar que una buena clasificación de “neither” (clase mayoritaria) infle artificialmente las métricas y nos va a permitir realizar una comparación directa con trabajos previos en stance detection que usan SemEval-2016.

4 Metodología

5 Análisis de resultados

6 Conclusiones

Bibliografía

- Alexandra Balahur. Sentiment analysis in social media texts. In *Proceedings of the 4th workshop on computational approaches to subjectivity, sentiment and social media analysis*, pages 120–128, 2013.
- Francesco Barbieri, Jose Camacho-Collados, Leonardo Neves, and Luis Espinosa-Anke. Tweeteval: Unified benchmark and comparative evaluation for tweet classification. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pages 1644–1650. Association for Computational Linguistics, 2020.
- Alessandro Bessi and Emilio Ferrara. Social bots distort the 2016 us presidential election online discussion. *First Monday*, 21(11), 2016. doi: 10.5210/fm.v21i11.7090.
- David M Blei, Andrew Y Ng, and Michael I Jordan. Latent dirichlet allocation. *Journal of Machine Learning Research*, 3(Jan):993–1022, 2003.
- Alexandre Bovet and Hernán A Makse. Influence of fake news in twitter during the 2016 us presidential election. *Nature Communications*, 10(1):7, 2019. doi: 10.1038/s41467-018-07761-2.
- DataCamp. ¿qué es el bert? introducción a los modelos bert, 2024. <https://www.datacamp.com/es/blog/what-is-bert-an-intro-to-bert-models>.
- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, volume 1, pages 4171–4186, 2019.
- Paul Ekman. An argument for basic emotions. *Cognition & Emotion*, 6(3-4):169–200, 1992.
- Andrea Esuli and Fabrizio Sebastiani. Sentiwordnet: A publicly available lexical resource for sentiment analysis and opinion mining. In *Proceedings of the 5th Conference on International Language Resources and Evaluation (LREC’06)*, pages 417–422, Génova, Italia, 2006. European Language Resources Association (ELRA).
- Anastasia Giachanou and Fabio Crestani. Like it or not: A survey of twitter sentiment analysis. *ACM Computing Surveys (CSUR)*, 49(2):1–42, 2016. doi: 10.1145/2938640.
- Yuriy Gorodnichenko, Tho Pham, and Oleksandr Talavera. Social media, sentiment and public opinions: Evidence from twitter and surveys. *Journal of Monetary Economics*, 118:236–254, 2021.

- Do-Gyeong Kim, Yuhwa Lee, Simon Washington, and Keechoo Choi. Modeling crash outcome probabilities at rural intersections: Application of hierarchical binomial logistic models. *Accident Analysis & Prevention*, 39(1):125–134, 2007.
- Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. Roberta: A robustly optimized bert pretraining approach. *arXiv preprint arXiv:1907.11692*, 2019.
- Alan Mislove, Sune Lehmann, Yong-Yeol Ahn, Jukka-Pekka Onnela, and J Niels Rosenquist. Understanding the demographics of twitter users. In *Proceedings of the International AAAI Conference on Web and Social Media*, volume 5, pages 554–557, 2011.
- Saif M Mohammad, Svetlana Kiritchenko, Parinaz Sobhani, Xiaodan Zhu, and Colin Cherry. Semeval-2016 task 6: Detecting stance in tweets. In *Proceedings of the 10th International Workshop on Semantic Evaluation (SemEval-2016)*, pages 31–41, San Diego, California, 2016. Association for Computational Linguistics. <https://aclanthology.org/S16-1003/>.
- Arun Mohan. Understanding distil bert in depth. Medium, November 2022. <https://arunm8489.medium.com/understanding-distil-bert-in-depth-5f2ca92cf1ed>.
- Alameen Najjar, Shun’ichi Kaneko, and Yoshikazu Miyanaga. Combining satellite imagery and open data to map road safety. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 31, 2017.
- Dat Quoc Nguyen, Thanh Vu, and Anh Tuan Nguyen. Bertweet: A pre-trained language model for english tweets. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations (EMNLP)*, pages 9–14. Association for Computational Linguistics, 2020. Accedido: 19/02/2026. <https://aclanthology.org/2020.emnlp-demos.2/>.
- World Health Organization. Despite notable progress, road safety remains urgent global issue, 2023. <https://www.who.int/news/item/13-12-2023-despite-notable-progress-road-safety-remains-urgent-global-issue>.
- Juan Ignacio Pérez. Cómo funcionan los Transformers en español. NLP, GPT, BERT. Aprende Machine Learning, 2020. <https://www.aprendemachinellearning.com/como-funcionan-los-transformers-espanol-nlp-gpt-bert/>.
- Sara Rosenthal, Noura Farra, and Preslav Nakov. Semeval-2017 task 4: Sentiment analysis in twitter. In *Proceedings of the 11th International Workshop on Semantic Evaluation (SemEval-2017)*, pages 502–518, Vancouver, Canadá, 2017. Association for Computational Linguistics.
- Chengcheng Shao, Giovanni Luca Ciampaglia, Onur Varol, Kai-Cheng Yang, Alessandro Flammini, and Filippo Menczer. The spread of low-credibility content by social bots. *Nature Communications*, 9(1):4787, 2018. doi: 10.1038/s41467-018-06930-7.
-

Theresa Wilson, Janyce Wiebe, and Paul Hoffmann. Recognizing contextual polarity in phrase-level sentiment analysis. In *Proceedings of the Conference on Human Language Technology and Empirical Methods in Natural Language Processing (HLT/EMNLP)*, pages 347–354, Vancouver, Canadá, 2005. Association for Computational Linguistics.

Lingfei Wu, Peng Cui, Jian Pei, Liang Zhao, and Xiaojie Guo. *Graph neural networks: foundation, frontiers and applications*. 2022.
